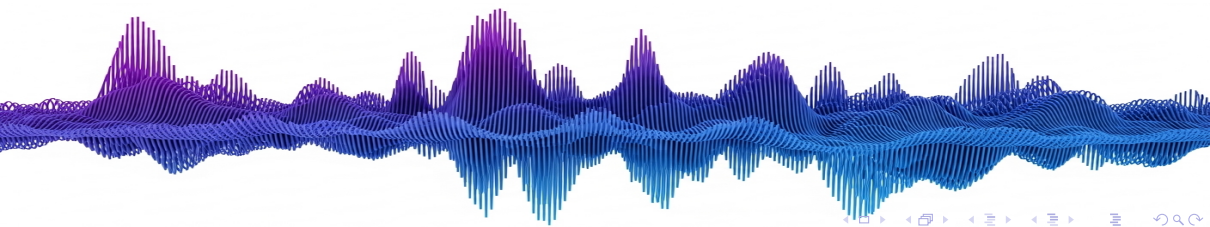
Aplicación de Redes Neuronales Para Estimar la Ubicación de Objetos Tridimensionales en Habitaciones Pequeñas Utilizando Ecos Acústicos

Tesis de Maestría en Computación

Autor: Esteban Padilla Padilla
Supervisor: Ing. Kervin Sánchez Herrera M.Sc.

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica

27 Junio 2025



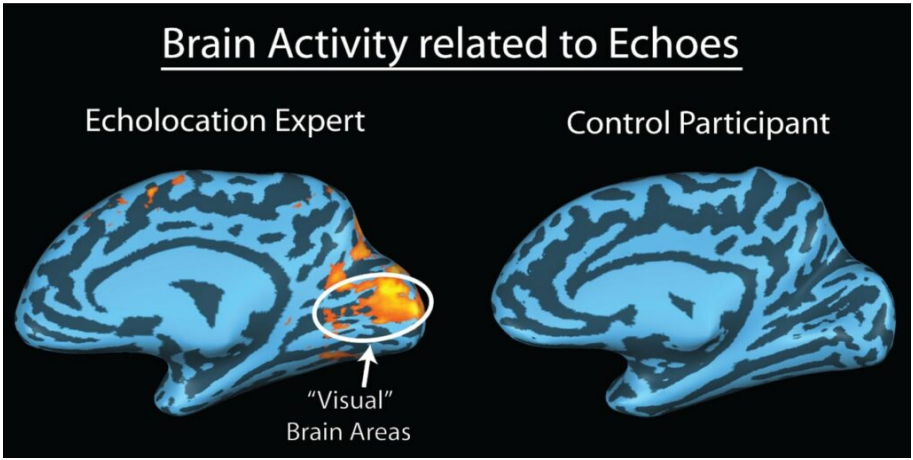


Figura 1: Imagen de resonancia magnética de actividad eléctrica en el cerebro para ecolocalización humana [1].

Tabla de Contenidos

1. Introducción
2. Trabajos Relacionados
3. Problema y Propuesta de Solución
4. Objetivos y Metodología
5. Metodología
6. Diseño

Respuesta al Impulso de una Habitación (**RIH**)

- El **RIH** es la función de trasferencia del sonido desde la fuente hasta los receptores.
- Es la "firma" de la acústica de una habitación.

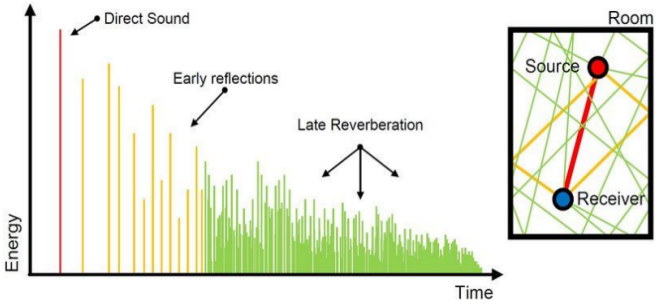


Figura 2: **RIH** y la representación geométrica de una habitación [2].

Beamforming

- Técnica de filtrado espacial.
- Usa arreglos de micrófonos para combinar señales.
- La relación de fase de las señales determina si amplifica o atenúa.

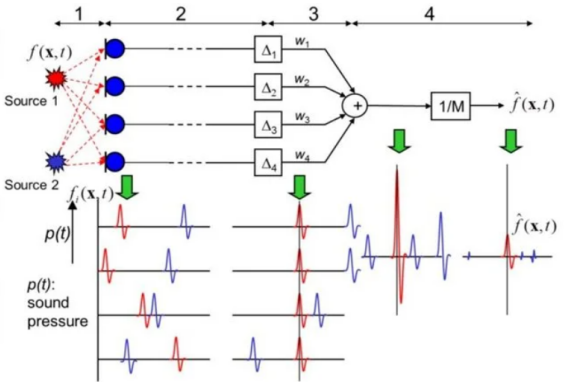


Figura 3: *Beamforming* por retraso y sumatoria [3].

Echo State Network (***ESN***)

- ***ESN*** es una red neuronal recurrente del paradigma de *Reservoir Computing* (***RC***).
- El *reservoir* es la parte recurrente de la red, este transforma secuencias de valores de entrada a estados en un espacio de alta dimensionalidad [1].
- El *reservoir* es estático, solo la salida de la red es entrenada.
- El entrenamiento es sencillo comparado con red recurrente tradicional.

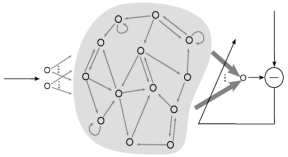


Figura 4: Red ESN con su *reservoir* resaltado en gris, las flechas obscuras indican entrenamiento [4].

[1] M. Lukoševičius and H. Jaeger. Reservoir computing approaches to recurrent neural network training. Computer Science Review, 3(3):127–149, 2009.

Trabajos Relacionados

Autores	Año	Logro	Tipo	Método
Peters et al.	2012	Identificación de habitaciones mediante sonido [5].	Clasificación	Aprendizaje automático
Dokmanić et al.	2013	Estimación de la forma de una habitación mediante ecos [6].	Estimación	Matrices euclidianas
Brunetto et al.	2020	Creación de imágenes de profundidad mediante ecos acústicos [7].	Generativo	Aprendizaje automático
Manabe et al.	2022	Reconocimiento de superficies y bordes de objetos usando ondas estacionarias [8].	Estimación	Espectros de distancia
Rothstein et al.	2023	Identificación estructuras cerradas desde su interior mediante ecos [9].	Clasificación	Aprendizaje automático
Wang et al.	2024	Detectar, localizar e identificar humanos dentro de habitaciones mediante sonidos [10].	Estimación	Aprendizaje automático
Bitterman et al.	2024	Clasificar habitaciones basado en tamaño y forma mediante RIH [11].	Clasificación	Aprendizaje automático

Tabla 1: Trabajos más significativos en percepción acústica de objetos y espacios.

Características Comunes

- La mayoría tiene como objetivo la identificación o la clasificación.
- Emplean enfoques de aprendizaje de maquina basados en redes *feedforward*.
- Por la dificultad de las mediciones acústicas emplean conjuntos de datos pequeños.
- Se enfocan en habitaciones grandes.

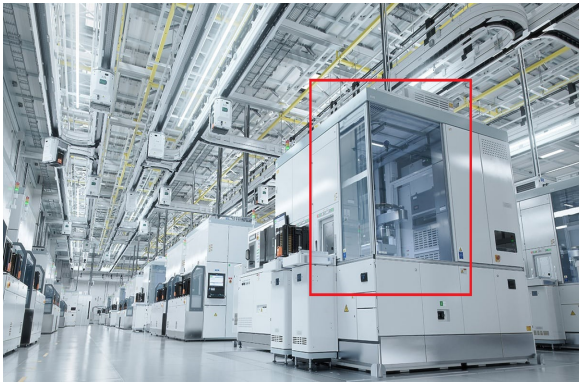


Figura 5: Piso de manufactura automatizado para semiconductores.

Problema

Lo anterior nos lleva a formular el siguiente problema:

- Para espacios pequeños (Aprox. $1m^3$) en donde su acústica presenta ecos que llegan de diferentes direcciones al mismo tiempo y se superponen se quiere estimar la posición y orientación de un objeto de interés dentro de ese espacio, esto mediante la respuesta a un impulso acústico.

Propuesta de Solución

Teniendo como entrada un conjunto de RIH, usar aprendizaje de máquina que transforme estas series acústicas en coordenadas de ubicación y ángulos de orientación de un objeto de interés en su interior.
Usando:

- *Beamforming* para resolver la superposición de ecos.
- Redes neuronales recurrentes en la forma de ESN para procesar directamente las series temporales.

Hipótesis

"Una secuencia de procesamiento que emplee *beamforming* y aprendizaje de máquina en la forma de ***ESN*** puede utilizar la información geométrica que esta comprendida en un conjunto de **RIH** para inferir o estimar la posición y orientación de un cubo de 20cm de lado ubicado dentro de un espacio pequeño, cuyas dimensiones sean cercanas a un metro [2], esto para cambios de posición no menores a 5cm en alguna de sus coordenada y cambios de orientación mayores a 10 grados, lo anterior con un error de posición menor a 2cm y de orientación menor a 6 grados [3]"

[2] Basado en las limitaciones encontradas por Brunetto et al. en el sistema de *Batvision* [7].

[3] Basado en las dimensiones de deformación detectables por Rothstein et al en su trabajo de *Echosense* [9].

Objetivo General

Desarrollar y evaluar un sistema por etapas que emplee *beamforming* junto con ***ESN*** para transformar una entrada multicanal de señales acústicas a coordenadas y ángulos que permitan estimar la ubicación de un objeto en un espacio cerrado.

Objetivos Específicos

- Colectar un conjunto de datos de la respuesta acústica de un espacio pequeño y cerrado para múltiples posiciones de un objeto dentro de este.
- Desarrollar una etapa de aprendizaje basado en redes neuronales convolucionales (*CNN*) que sea la referencia para estimar coordenadas y orientación de un objeto dentro de un espacio cerrado.
- Desarrollar una etapa de aprendizaje que use *ESN* para estimar coordenadas y orientación de un objeto dentro de un espacio cerrado.
- Implementar un etapa de *beamforming* que permita dividir el espacio en ocho regiones de audición.
- Evaluar experimentalmente la exactitud y precisión de los estimadores.

Metodología: Caja de Medición

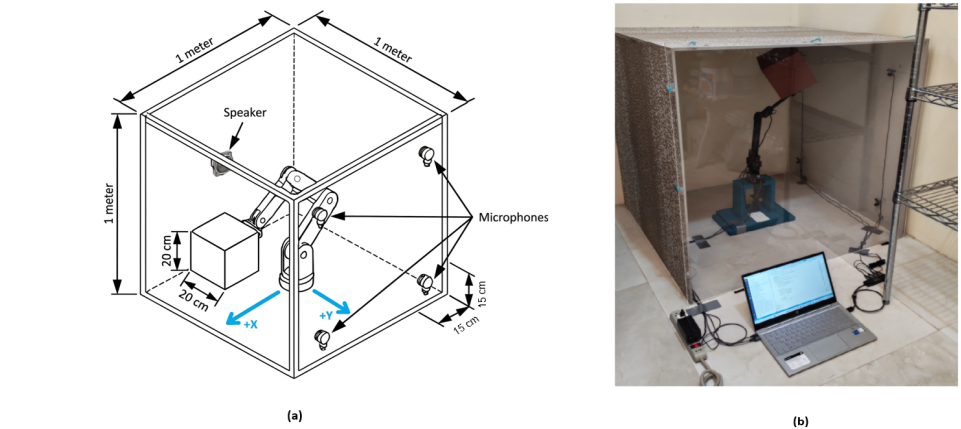
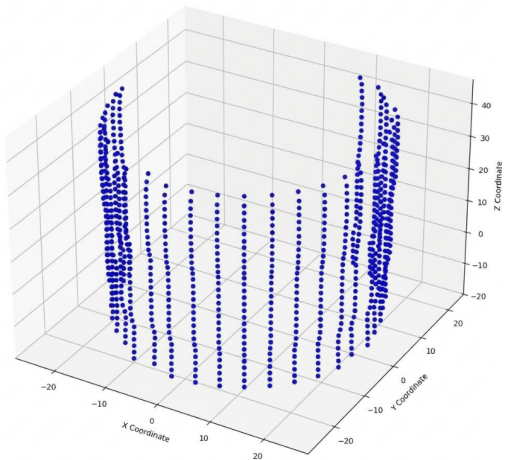


Figura 6: Caja de medición: (a) esquema conceptual de la caja para mediciones acústicas y (b) implementación real para la adquisición de datos.

Metodología: Recolección de Datos

- La señal era un fragmento de 0,3 segundos de una melodía.
- El conjunto de datos se recopiló en 26 sesiones.
- Cada sesión consistió en 30 ubicaciones distintas del cubo.
- En cada ubicación se registraron nueve orientaciones del cubo.
- Por sesión se obtuvieron 270 muestras a cuatro canales cada una.
- En total se obtuvieron 7020 muestras a cuatro canales cada una.



Metodología: Procesamiento de los Datos

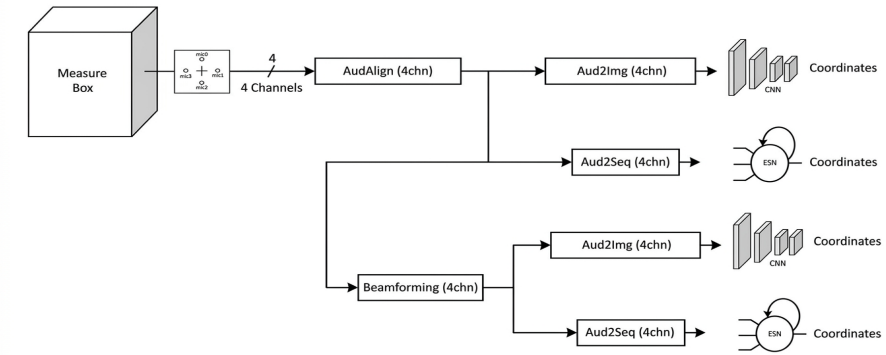


Figura 8: Diagrama con las etapas de procesamiento de datos de los estimadores.

Metodología: Análisis de los Datos

- Se emplea *five-fold cross-validation* para el entrenamiento y evaluacion de los modelos.
- Se evaluan dos métricas:
  - *Mean Absolute Error (MAE)*.
  - El coeficiente de Pearson.
- Se presenta la distribución de los errores de estimación para cada coordenada.
- Se comparan los resultados mediante el modelo bayesiano de Plackett-Luce.

CNN

- Log-Mel spectrogramas como entrada para la CNN.
- Arquitectura ResNet-18: $\sim$ 11 millones de parámetros.
- La entrada es un stack de 4 imágenes de espectrogramas RGB.
- Única salida de regresión con función de activación sigmoidal.
- Normalización min-max y arcsin.
- Entrenado por 40 épocas: $\sim$1.2 horas.

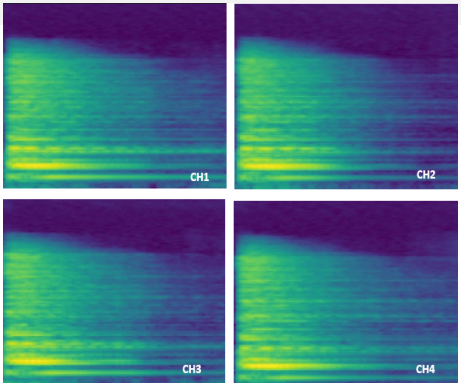


Figura 9: Espectrogramas Log-Mel sesión 1, en la ubicación X=22.8 cm, Y=-0.94 cm, Z=-9.43 cm y con una orientación de 50 grados.

ESN

- Secuencia de espectrogramas como entrada para la ESN con 128 features por 40 frames.
- Grid search para la optimización de hiperparámetros.

Tabla 2: Echo State Network (ESN) Hyperparameters

Parameter	Value
Reservoir Size	1500
Spectral Radius	0.99
Sparsity	0.1
Leaky Rate	0.1
Intermediate Captures	4

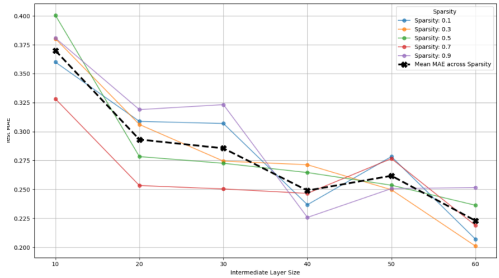


Figura 10: MAE en función del tamaño de la capa oculta para distintos valores de *sparsity*.

Multihead ESN

- ESN con MAE $>$ 2cm y solamente 62 % de las estimaciones con errores inferiores a ± 2 cm.
- Multihead ESN para mejorar la precisión de las estimaciones.
- Entrenada cada cabeza de manera independiente, Total $\sim$ 1.5h.

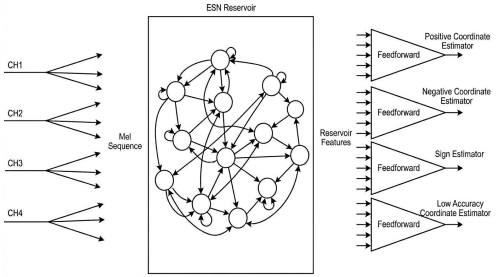


Figura 11: Arquitectura de la red multi-cabeza para el estimador ESN.

Beamforming

- Frecuencia minima de operación 123 Hz.
- Senal de audio de 10kHz ancho de banda con principales componentes a 400 Hz.
- Diferencia en tiempo de llegada entre los micrófonos de 1.34ms a una velocidad de sonido de 343 m/s.
- Cuatro pares diferenciales de audio obtenidos como resultado.

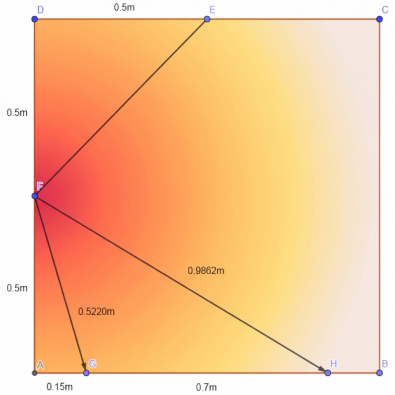


Figura 12: Geometric layout of the measurement box illustrating the acoustic path from the speaker located at E to the microphones positioned at G and H

Aspectos clave de contribución de la tesis:

- Demostraría que es posible localizar y determinar la orientación de un objeto en un espacio pequeño.
- Demostraría que *beamforming* es una opción para solucionar el problema de superposición de ecos en espacios pequeños.
- Indicaría que ESN es mejor que CNN para análisis de ecos acústicos.


GRACIAS
THANK YOU
Obrigado
Thank You
Asante
Merci
Grazie
Vinaka
Spasibo
Arigato
Welalin
Kiitos
Chokrane
Juspaxar
Mamana
Matondo
Salamat
Matur Nuwun
Terma Kasih
Mochchakkeram
Dank Je
Cam on ban
Maake
Danken

Referencias I

- L. Thaler, “Echolocation in people,” 2022.
- F. Samad, “Using audio ray tracing to calculate room impulse response,” 2009.
- Polytec, “Beamforming,” 2025.
- M. Lukoševičius and H. Jaeger, “Reservoir computing approaches to recurrent neural network training,” *Computer Science Review*, vol. 3, no. 3, pp. 127–149, 2009.
- N. Peters, H. Lei, and G. Friedland, “Name that room: room identification using acoustic features in a recording,” MM ’12, (New York, NY, USA), p. 841–844, Association for Computing Machinery, 2012.
- I. Dokmanić, R. Parhizkar, A. Walther, Y. M. Lu, and M. Vetterli, “Acoustic echoes reveal room shape,” *Proceedings of the National Academy of Sciences*, vol. 110, no. 30, pp. 12186–12191, 2013.

Referencias II

- A. Brunetto, S. Hornauer, S. X. Yu, and F. Moutarde, "The audio-visual batvision dataset for research on sight and sound," in *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, p. 1–8, IEEE, Oct. 2023.
- T. Manabe, R. Fukunaga, K. Nakatsuma, and M. Kumon, "Object surface recognition using microphone array by acoustic standing wave," in *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 9274–9279, 2022.
- M. Rothstein, Z. Liu, and I. Bashima, "Echosense: Acoustic sensing for enclosed structure monitoring and recognition," in *2023 IEEE MIT Undergraduate Research Technology Conference (URTC)*, pp. 1–6, 2023.
- M. Wang, S. Clarke, J.-H. Wang, R. Gao, and J. Wu, "Soundcam: A dataset for finding humans using room acoustics," 2024.

Referencias III

J. Bitterman, D. Levi, H. H. Diamandi, S. Gannot, and T. Rosenwein, “Revrir: Joint reverberant speech and room impulse response embedding using contrastive learning with application to room shape classification,” 2024.